

RLC Filter Identification from Input–Output Signals

20221242 박수빈

목차

1. 설계 목적
2. 기본 이론
3. 코드 설명
4. 실행 결과 및 결론

설계 목적

1. 미지의 필터를 입출력 신호를 통해 판별
2. 1차 RC 필터와 2차 RLC 필터(LP, HP, BP)을 모두 고려하여 비교
3. 최종적으로 필터 종류, 파라미터, 신뢰도 자동으로 산출

기본 이론 - Green's Function과 전달 함수



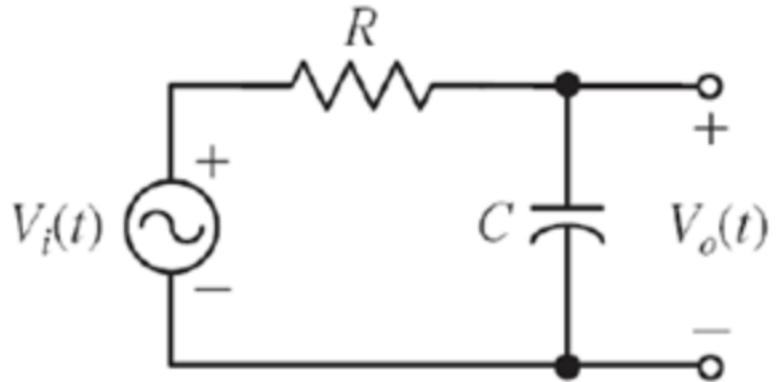
$$V_{out}(t) = \int_0^t K(t-\tau)V_{in}(\tau)d\tau$$

$$\mathcal{F}\{V_{out}(t)\} = \mathcal{F}\{K(t)\}\mathcal{F}\{V_{in}(t)\}$$

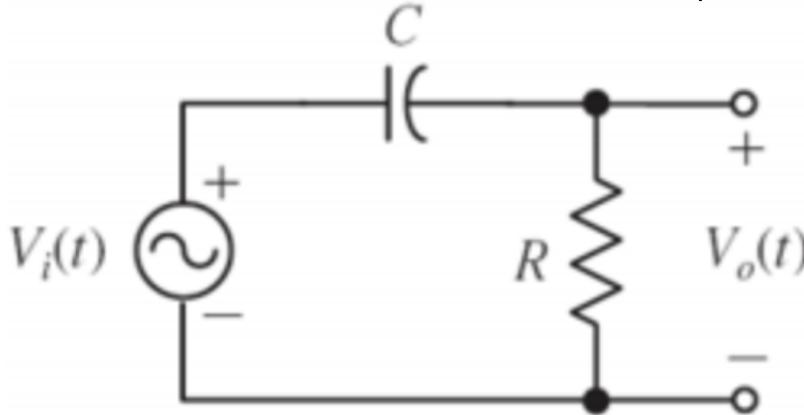
$$\mathcal{F}\{K(t)\} = H(j\omega) = \frac{V_{out}(j\omega)}{V_{in}(j\omega)}$$

기본 이론 - 1차 필터와 2차 필터

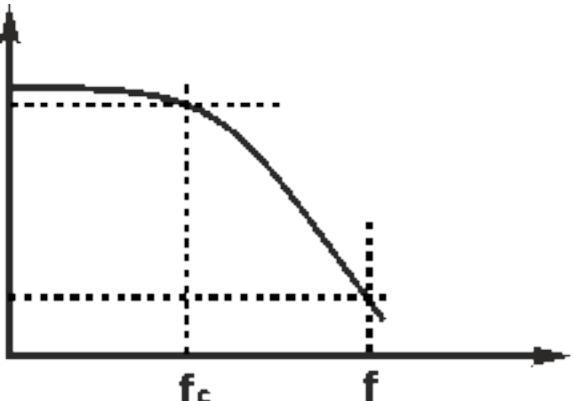
1차 저역통과 필터 (LPF)



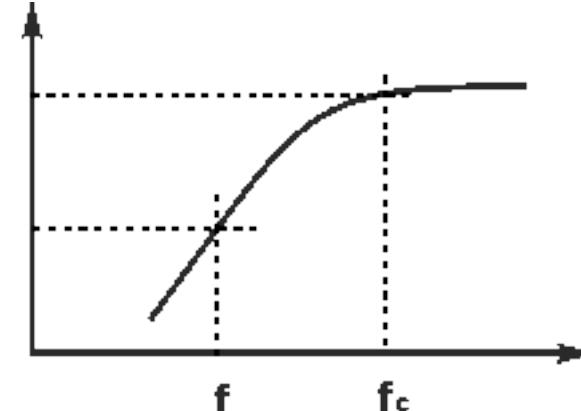
1차 고역통과 필터 (HPF)



$$H(s) = \frac{1}{sRC + 1}$$



$$H(s) = \frac{sRC}{sRC + 1}$$



$$\omega_c = \frac{1}{RC}$$

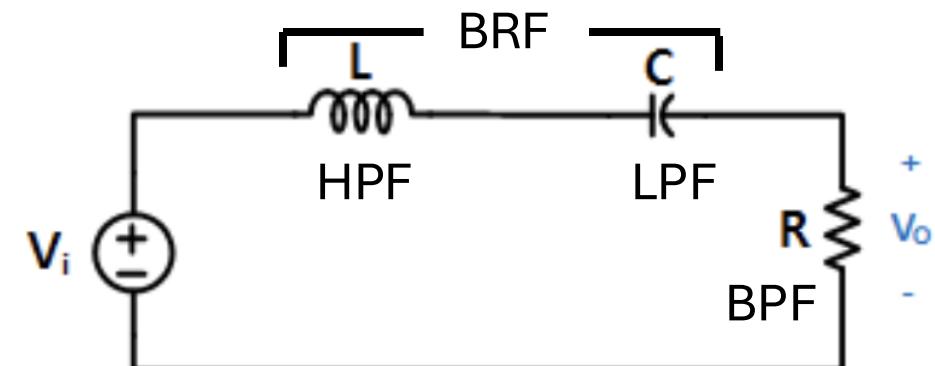
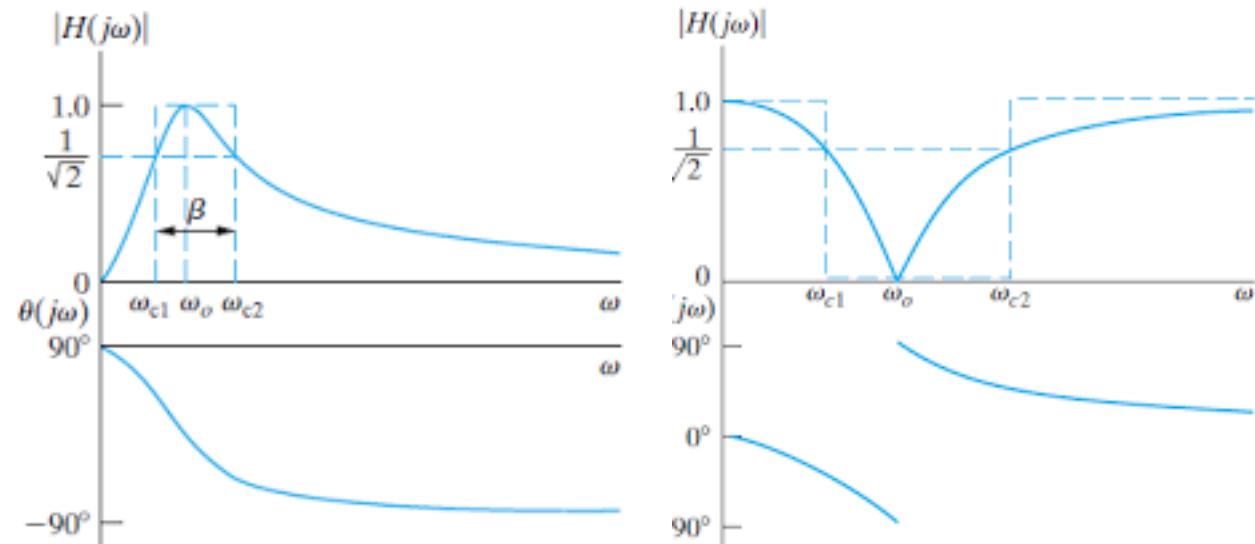
기본 이론 - 1차 필터와 2차 필터

저역통과 필터 (LPF) $H(s) = \frac{\omega_0^2}{s^2 + \frac{\omega_0}{Q}s + \omega_0^2}$

고역통과 필터 (HPF) $H(s) = \frac{s^2}{s^2 + \frac{\omega_0}{Q}s + \omega_0^2}$

대역통과 필터 (BPF) $H(s) = \frac{s \frac{\omega_0}{Q}}{s^2 + \frac{\omega_0}{Q}s + \omega_0^2}$

대역차단 필터 (BRF) $H(s) = \frac{s^2 + \omega_0^2}{s^2 + \frac{\omega_0}{Q}s + \omega_0^2}$



$$\omega_0 = \frac{1}{\sqrt{LC}}, \quad Q = \frac{1}{R} \sqrt{\frac{L}{C}}$$

코드 설명

1. FFT 기반 전달함수 추정, 필터별 전달함수 정의
2. 필터 피팅 함수 정의 및 신뢰도 분석
3. 필터 결정 및 Bode Plot 그리기
4. RLC 매핑
5. 입력 CSV 로드, UI 설정

코드 설명 - FFT 기반 전달함수 추정, 필터별 전달함수

```
def estimate_transfer_function(x, y, dt, f_max=None,
| | | | | | | | min_input_amp=1e-6, min_H_mag=None):
| |
x(t), y(t)로부터 FFT 기반  $H(\omega) = Y(\omega)/X(\omega)$  추정.
|
x = np.asarray(x, dtype=float)
y = np.asarray(y, dtype=float)
n = len(x)
if len(y) != n:
    raise ValueError("x와 y의 길이가 같아야 합니다.")

X = np.fft.rfft(x)
Y = np.fft.rfft(y)
freqs = np.fft.rfftfreq(n, dt)
w = 2 * np.pi * freqs

H = Y / X

X, Y에 대해 푸리에 변환,
전달 함수 계산

mask = np.abs(X) > min_input_amp # 입력 신호가 충분히 큰 구간만 사용
mask &= freqs > 0

if f_max is not None:
    mask &= freqs <= f_max

if min_H_mag is not None: # H 크기가 너무 작은 구간은 버리기
    mask &= (np.abs(H) > min_H_mag)

if not np.any(mask):
    raise RuntimeError("유효한 주파수 구간이 없습니다.")

return freqs[mask], w[mask], H[mask]
```

```
# =====#
# 1·2차 표준형 전달함수
# =====#
def H_1st_LP(w, K, wc):           비교할 필터 전달 함수 정의
    return K / (1 + 1j*w/wc)
def H_1st_HP(w, K, wc):
    return K * (1j*w/wc) / (1 + 1j*w/wc)
def _den(w, w0, Q):
    return (1j*w)**2 + (w0/Q)*(1j*w) + w0**2
def H_2nd_LP(w, K, w0, Q):
    return K * (w0**2) / _den(w, w0, Q)
def H_2nd_HP(w, K, w0, Q):
    return K * ((1j*w)**2) / _den(w, w0, Q)
def H_2nd_BP(w, K, w0, Q):
    return K * ((w0/Q)*(1j*w)) / _den(w, w0, Q)
def H_2nd_BR(w, K, w0, Q):
    return K * ((1j*w)**2 + w0**2) / _den(w, w0, Q)
```

코드 설명 - 필터 피팅 함수 정의, 신뢰도 분석

```
# =====
# 피팅
# =====

@dataclass
class FitResult:
    name: str      피팅 결과 담을 클래스 정의
    params: dict
    mse: float

def fit_complex(w, H_meas, func, p0, bounds):
    """
    복소 전달함수 H_meas(w)에 대해
    H_pred(w, p)를 least_squares로 피팅.
    """

    def residual(p):
        H_pred = func(w, *p) 예상 모델 정의
        diff = H_pred - H_meas
        return np.concatenate([diff.real, diff.imag])
            복소 오차를 실수 벡터로 반환
    res = least_squares(residual, p0, bounds=bounds)
    p = res.x      측정된 모델과 차이가 최소가 되는 파라미터
    H_pred = func(w, *p)
    mse = np.mean(np.abs(H_pred - H_meas)**2)
    return p, mse  mse: 예측 값과 실제 값의 차이
```

```
def analyze_confidence(models, ambiguous_ratio=0.1):
    """
    models: dict[str, FitResult]
    반환:
        { "best": best_result,
          "top3": [FitResult, ...],
          "rel_gap_12": 상대 차이,
          "confidence": 0~1,
          "ambiguous": True/False }

    results = sorted(models.values(), key=lambda r: r.mse)
    best = results[0]
    top3 = results[:3]      mse 작은 순으로 필터 정렬

    mse_best = best.mse
    if len(results) > 1:
        mse_second = results[1].mse
        rel_gap_12 = (mse_second - mse_best) / (mse_best + 1e-12)
    else:
        mse_second = None
        rel_gap_12 = float("inf")

    raw_conf = max(0.0, min(1.0, rel_gap_12 / 0.5)) # 50% 차이면 ~1
    ambiguous = (rel_gap_12 < ambiguous_ratio)

    return {
        "best": best,
        "top3": top3,
        "rel_gap_12": rel_gap_12,
        "confidence": raw_conf,
        "ambiguous": ambiguous,
    }
```

1, 2위 모델 간 mse 차이 계산, 신뢰도 계산
신뢰도 적으면 ambiguous = 1 반환

코드 설명 - 필터 결정

```
def identify_order12_filter(x, y, dt, f_max=None, show_bode=True):
    """
    x(t) → 시스템 → y(t) 에 대해
    1차/2차 표준형 필터(LP, HP, BP, BR) 중 하나로 피팅.
    """
    freqs, w, H_meas = estimate_transfer_function(x, y, dt, f_max=f_max,
                                                   min_input_amp=1e-6, min_H_mag=1e-3)
    mag = np.abs(H_meas)
    K0 = np.median(mag) if np.median(mag) > 0 else 1.0
    w_mid = np.median(w)
    wc0 = w_mid if w_mid > 0 else 1e3
    idx_pk = np.argmax(mag)
    w0_0 = w[idx_pk] if w[idx_pk] > 0 else 1e3
    Q0 = 1.0

    models = {}
```

필터 피팅 함수를 모든 모델에 적용
mse 작은 최적 모델 찾기

```
# 1st models
p0 = [K0, wc0]
b1 = ([0, 1e-3], [1e3*K0, 1e9])
# 1st LP
p, mse = fit_complex(w, H_meas, H_1st_LP, p0, b1)
models["1st_LP"] = FitResult(
    "1st_LP",
    {"K": float(p[0]), "wc": float(p[1])},
    float(mse)
)
# 1st HP
p, mse = fit_complex(w, H_meas, H_1st_HP, p0, b1)
models["1st_HP"] = FitResult(
    "1st_HP",
    {"K": float(p[0]), "wc": float(p[1])},
    float(mse)
)
# 2nd models
b2 = ([0, 1e-3, 0.1], [1e3*K0, 1e9, 100])
for name, func in {
    "2nd_LP": H_2nd_LP,
    "2nd_HP": H_2nd_HP,
    "2nd_BP": H_2nd_BP,
    "2nd_BR": H_2nd_BR,
}.items():
    p0 = [K0, w0_0, Q0]
    p, mse = fit_complex(w, H_meas, func, p0, b2)
    models[name] = FitResult(
        name,
        {"K": float(p[0]), "w0": float(p[1]), "Q": float(p[2])},
        float(mse)
)
best = min(models.values(), key=lambda r: r.mse)
conf_info = analyze_confidence(models, ambiguous_ratio=0.1)
```

실행 결과 - 입력 위젯

RLC 필터 식별기

Mode

fs [Hz]

CSV 모드에서 사용할 파일 이름

x CSV

y CSV

Wave 모드: x 설정

x type

x phase

x A

x t0

x f[Hz]

Wave 모드: y 설정

y type

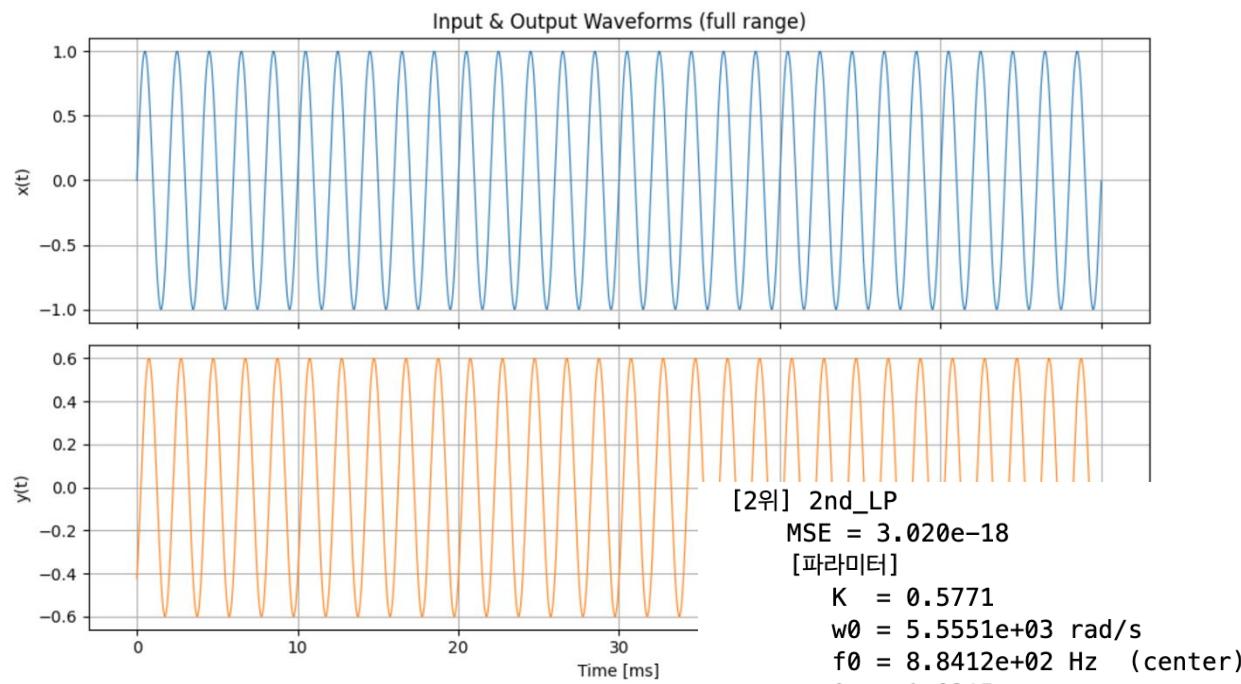
y phase

y A

y t0

y f[Hz]

실행 결과 - 출력 결과 (사인파 입출력)



== 최종 선택된 모델 (Best) ==

필터 타입: 1st_LP

[파라미터]

K = 0.8485

wc = 3.1416e+03 rad/s

fc = 5.0000e+02 Hz (cutoff)

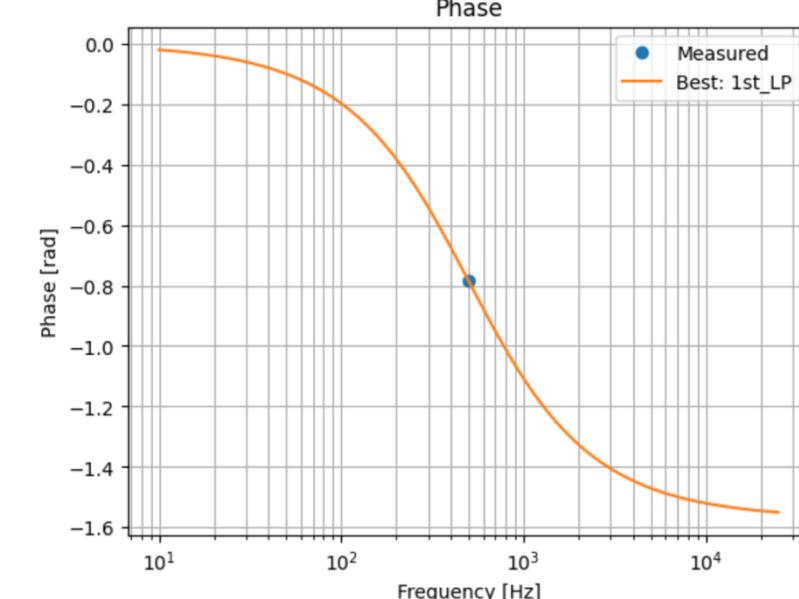
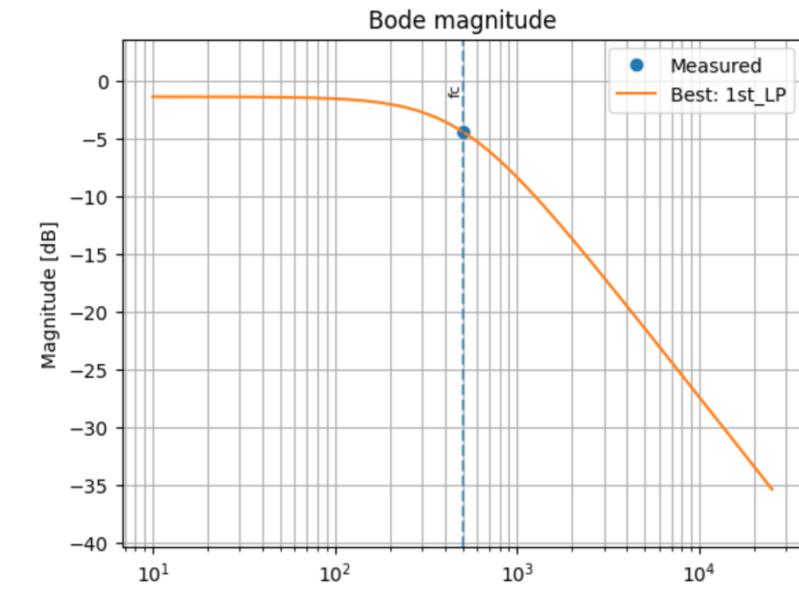
[RLC 값]

R = 3.1831e+05

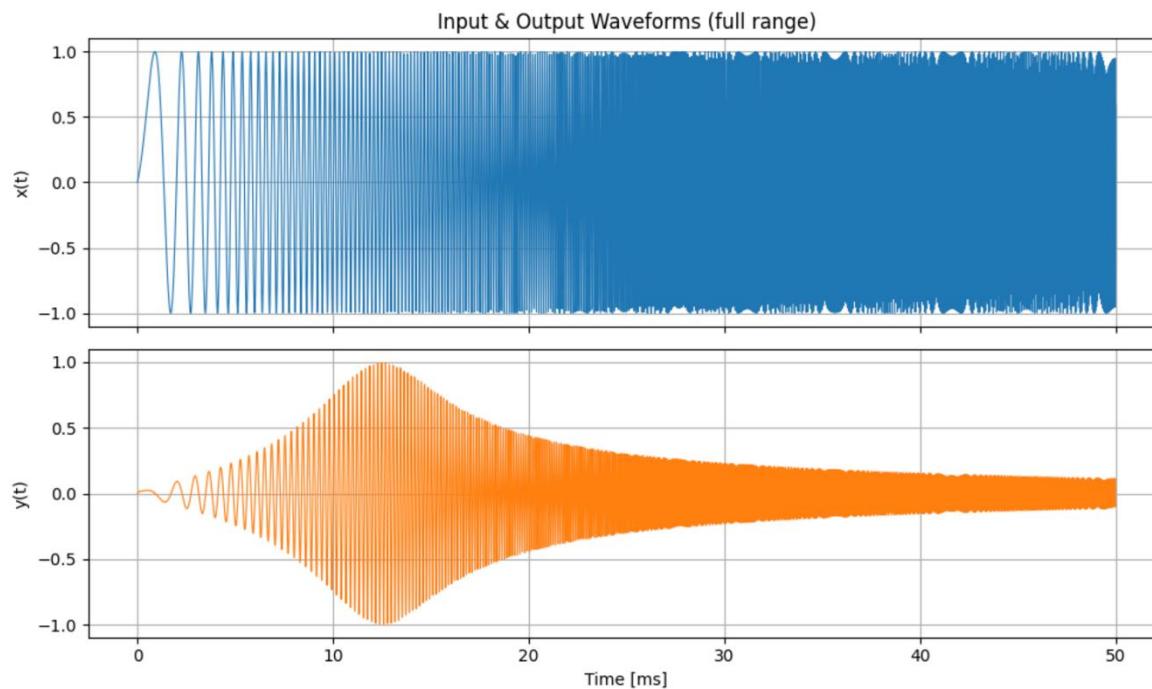
C = 1.0000e-09

Confidence score = 0.000

(주의: 1위와 2위 모델의 MSE 차이가 작음.)



실행 결과 - 출력 결과 (Chirp 입출력 - BPF)



== 최종 선택된 모델 (Best) ==

필터 타입: 2nd_BP

[파라미터]

K = 0.9907

w0 = 3.1386e+04 rad/s

f0 = 4.9953e+03 Hz (center)

Q = 2.0987

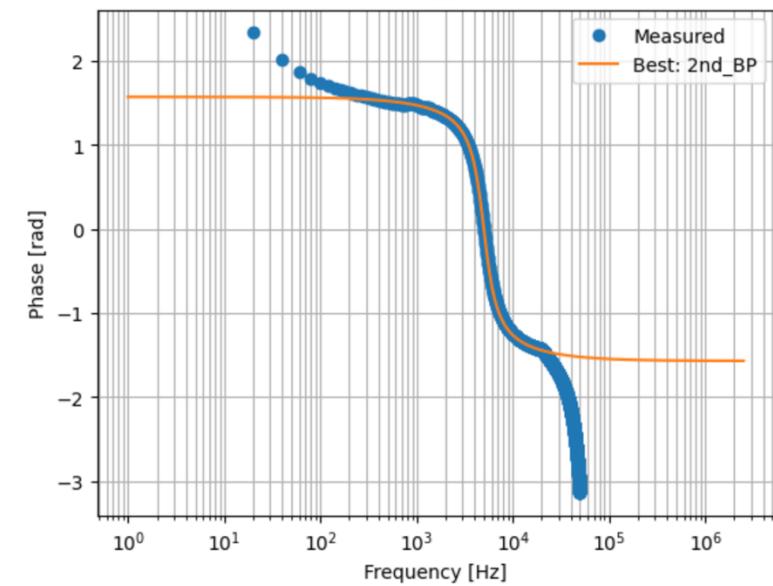
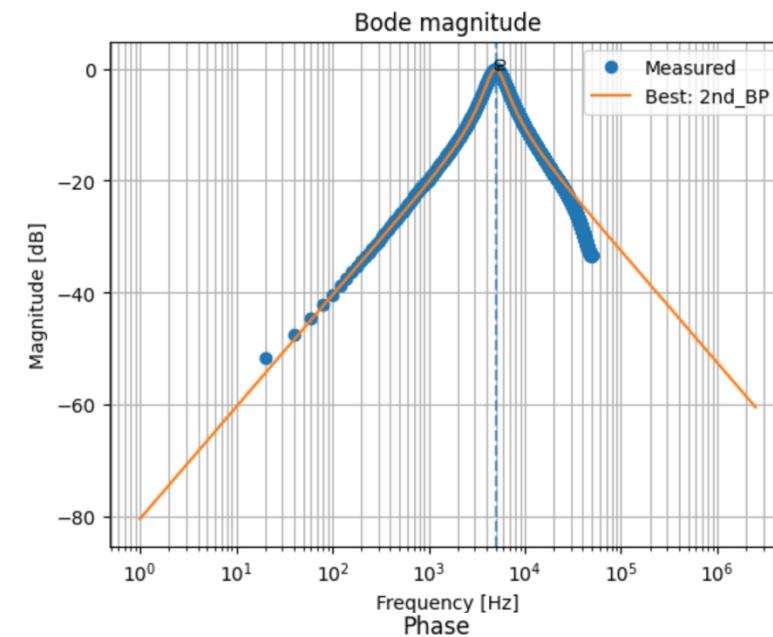
[RLC 값]

R = 1.5181e+04

L = 1.0151e+00

C = 1.0000e-09

Confidence score = 1.000

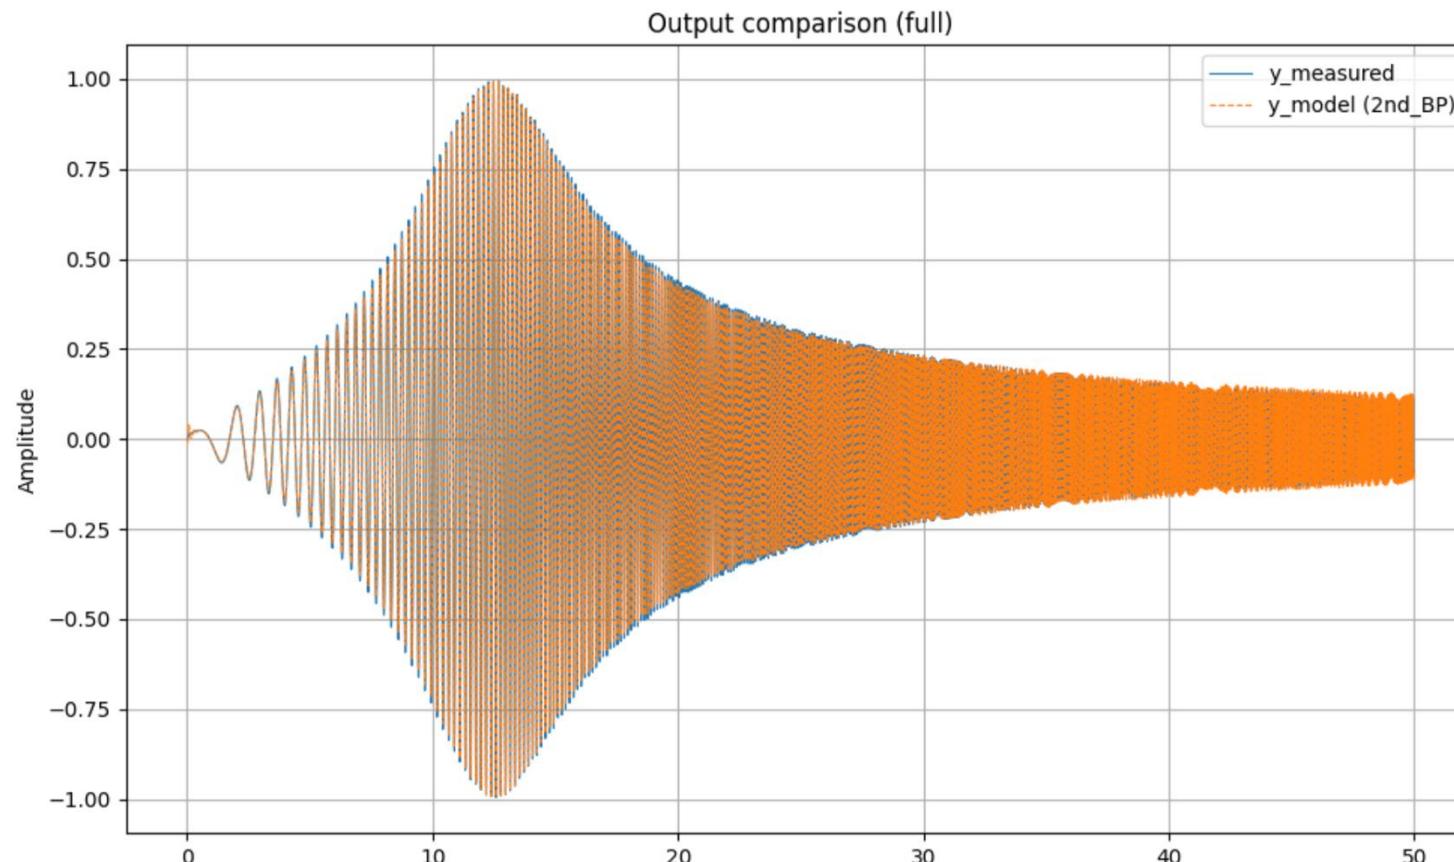


실행 결과 - 출력 결과 (Chirp 입출력 - BPF)

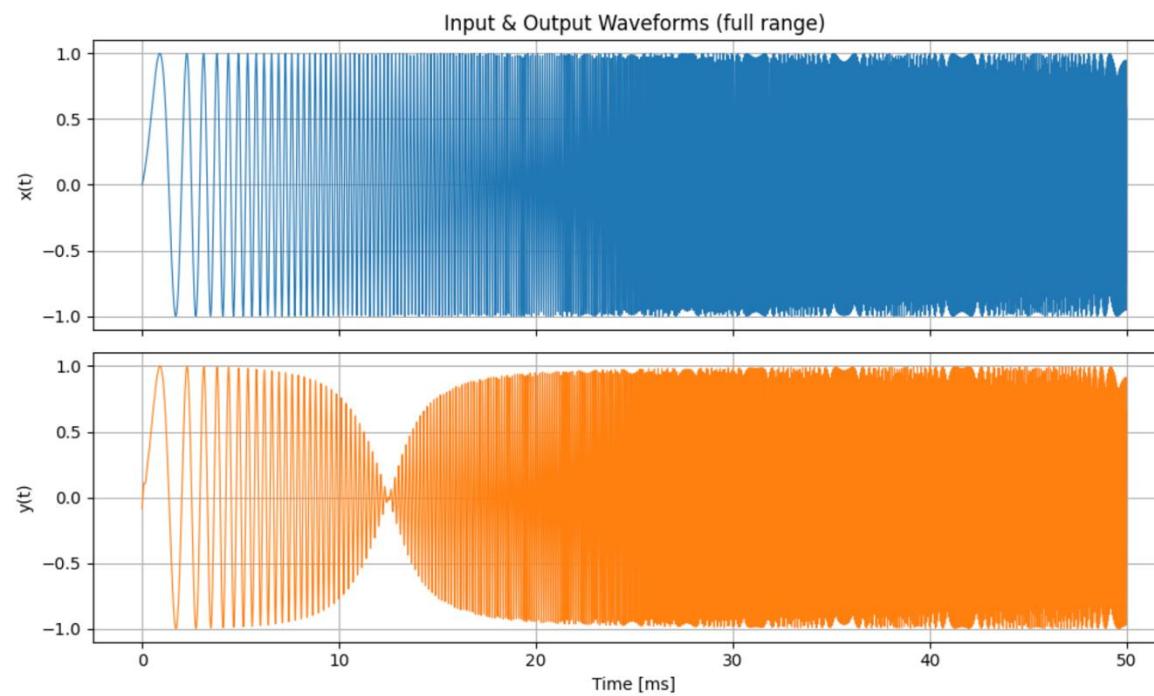
추가) 모델 검증

예측 모델에 입력 파형 넣어 얻은 출력 파형과 실제 출력 파형 비교

정렬된 신호: N=4999, dt=1.000e-05
MSE(y_{model} , y_{meas}) = 7.501e-05



실행 결과 - 출력 결과 (Chirp 입출력 - BRF)



==== 최종 선택된 모델 (Best) ====

필터 타입: 2nd_BR

[파라미터]

$$K = 1.0497$$

$$\omega_0 = 3.1416e+04 \text{ rad/s}$$

$$f_0 = 5.0000e+03 \text{ Hz (center)}$$

$$Q = 2.8825$$

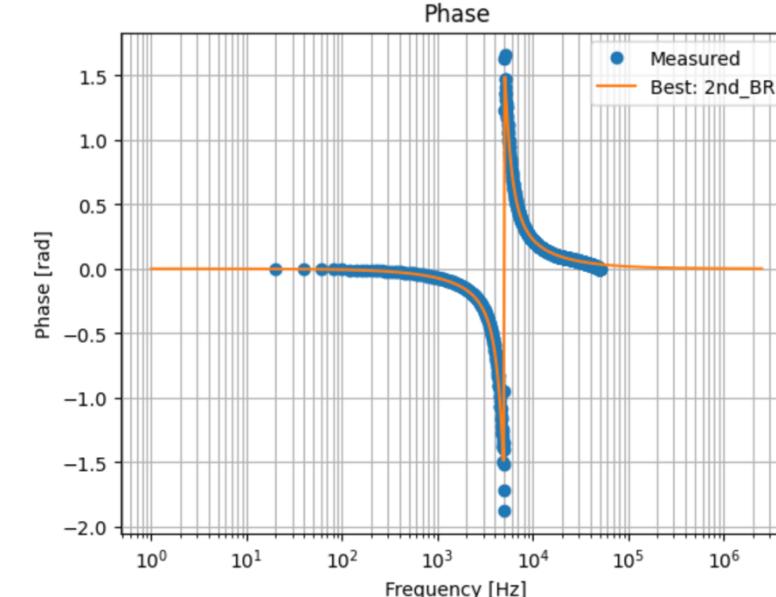
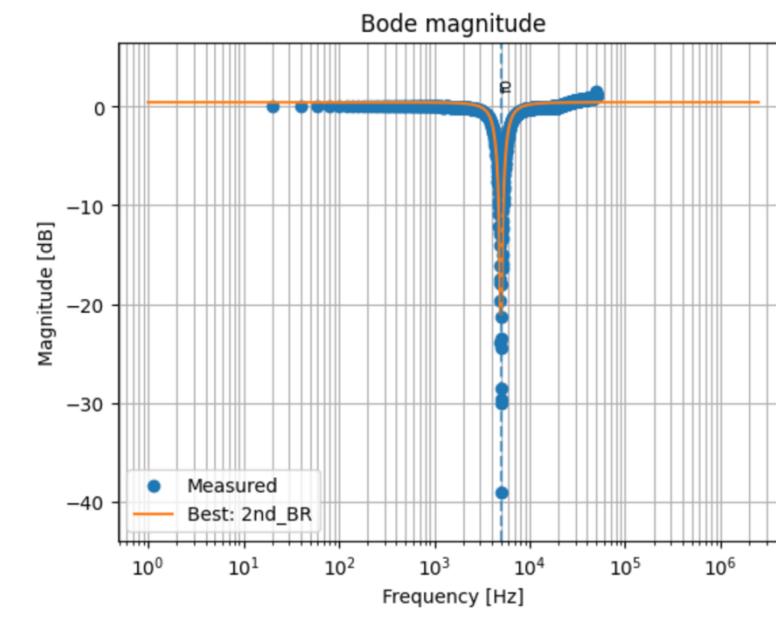
[RLC 값]

$$R = 1.1043e+04$$

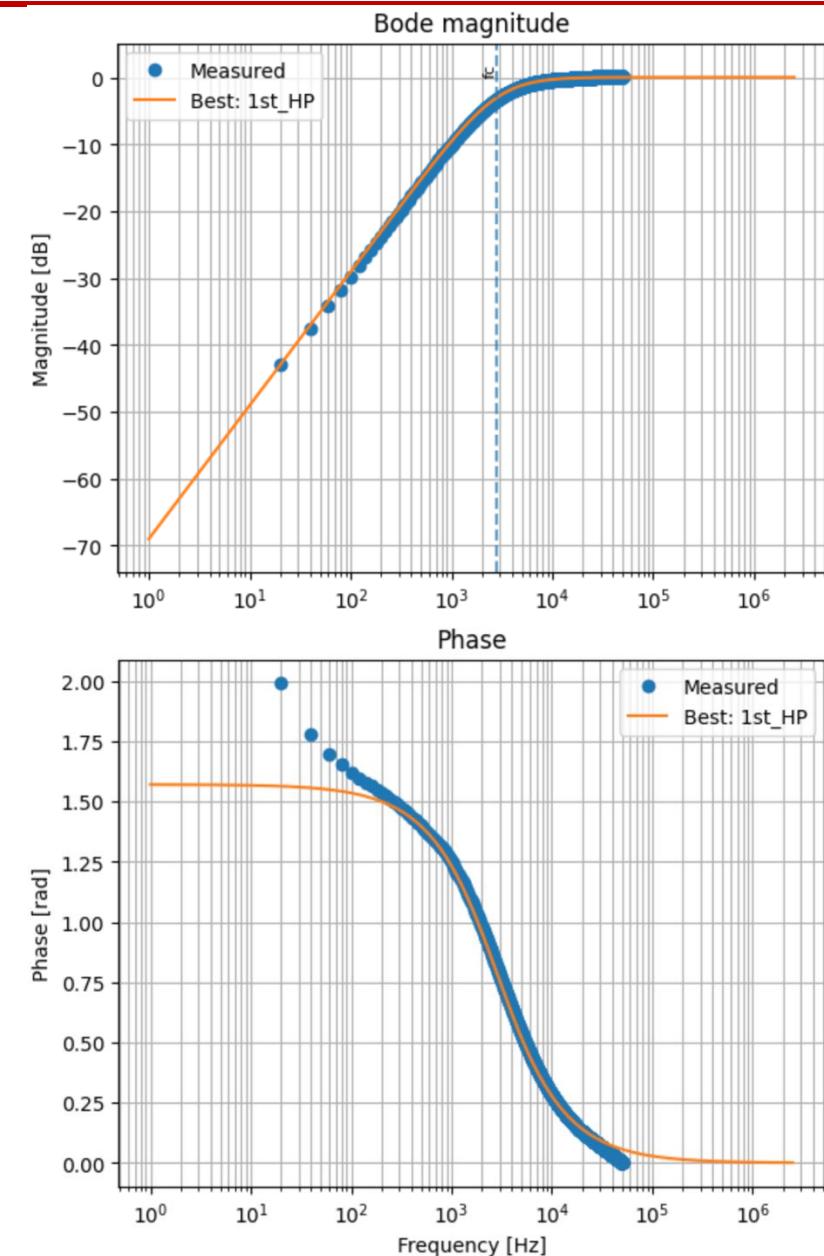
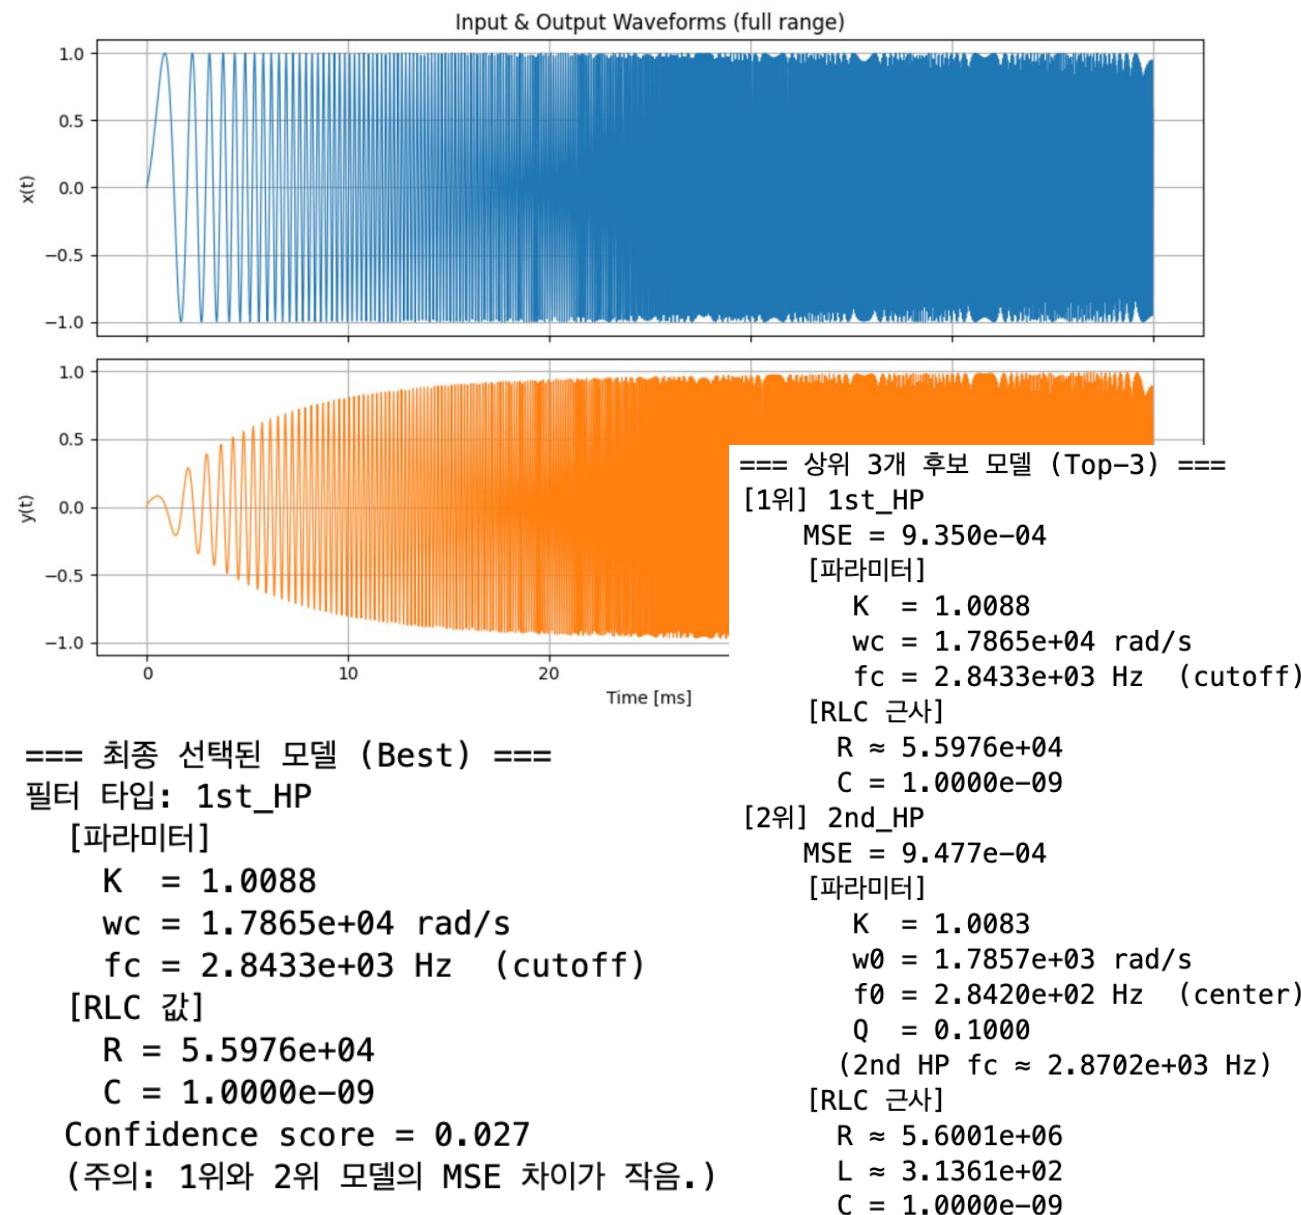
$$L = 1.0132e+00$$

$$C = 1.0000e-09$$

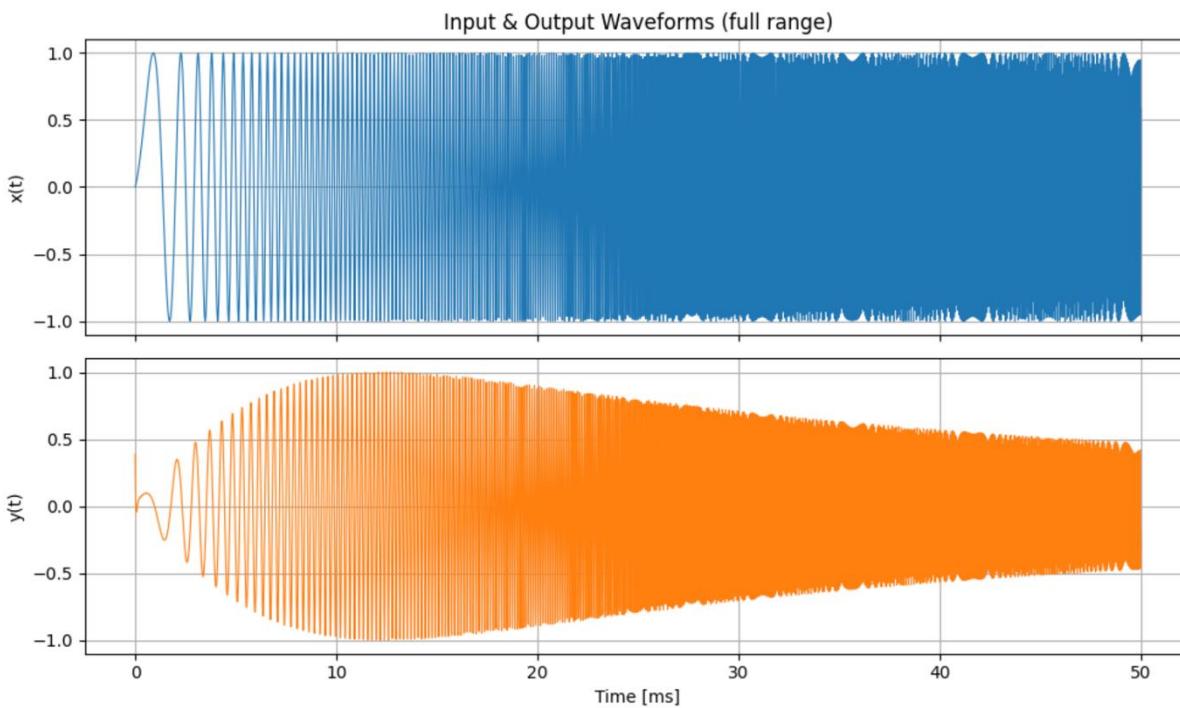
Confidence score = 1.000



실행 결과 - 출력 결과 (Chirp 입출력 - 1st HPF)



실행 결과 - 출력 결과 (Chirp 입출력 - low-Q BPF)



== 최종 선택된 모델 (Best) ==

필터 타입: 2nd_LP

[파라미터]

K = 0.6578

w0 = 1.5469e+05 rad/s

f0 = 2.4620e+04 Hz (center)

Q = 0.8097

[2nd LP cutoff]

wc = 1.0883e+05 rad/s

fc = 1.7321e+04 Hz

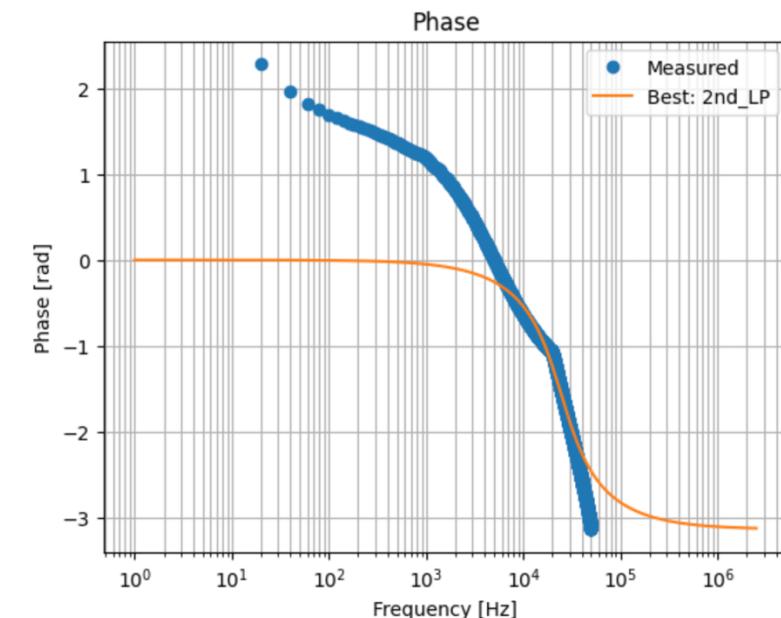
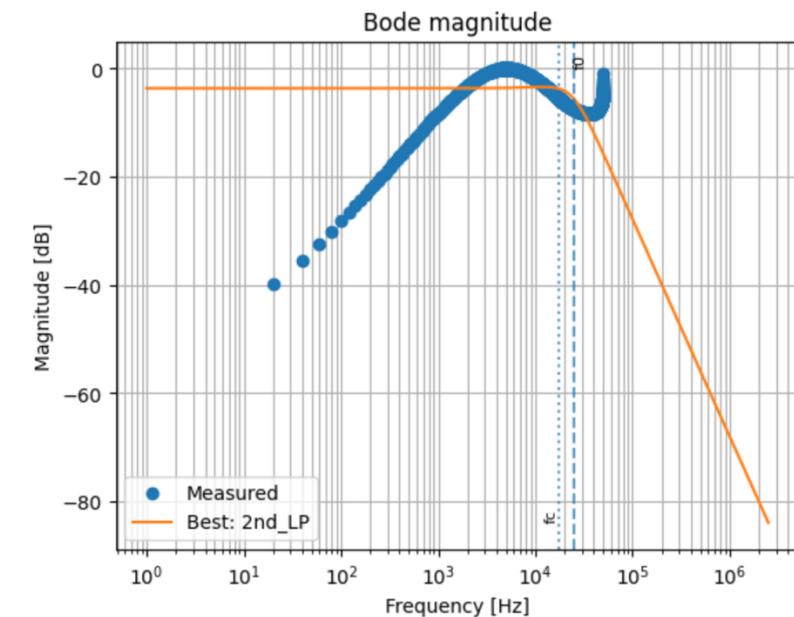
[RLC 값]

R = 7.9838e+03

L = 4.1789e-02

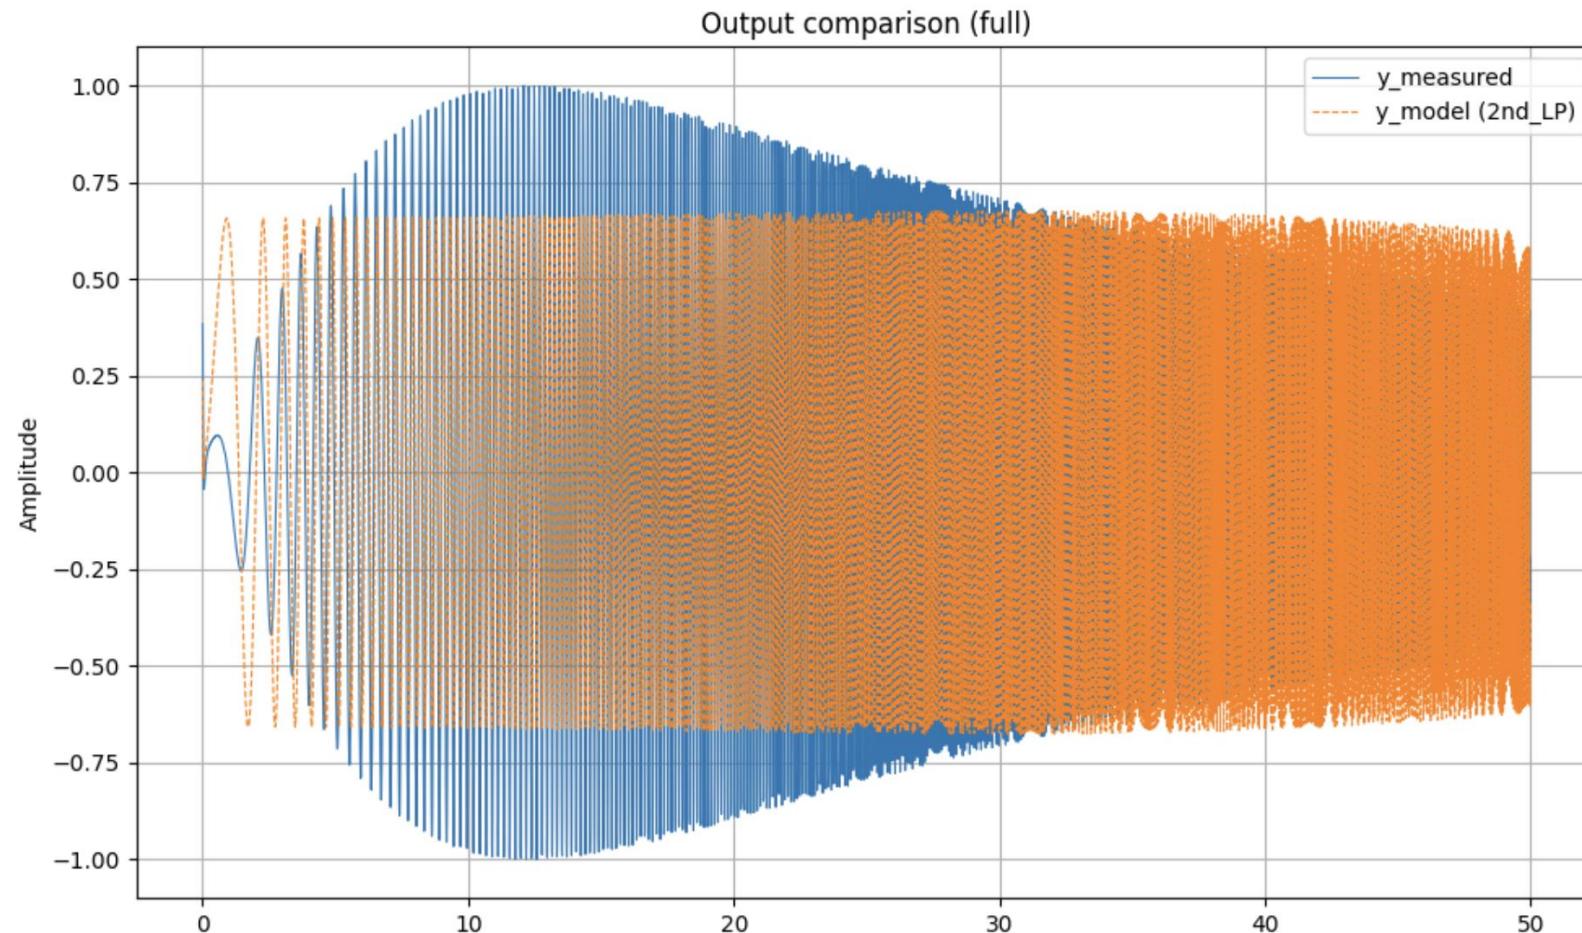
C = 1.0000e-09

Confidence score = 0.251



실행 결과 - 출력 결과 (Chirp 입출력 - low-Q BPF)

정렬된 신호: N=4999, dt=1.000e-05
MSE(y_{model} , y_{meas}) = 4.936e-02



결론

- 입출력 신호를 통해 다양한 필터 비교 후 최적의 필터 도출 가능
- 전달함수 크기가 작을 때 측정값이 튕는 불안정성
- Q가 작은 필터 식별 어려움